四川大学计算机学院学院 实验报告

学号: <u>2017141461179</u> 姓名: <u>王兆基</u> 专业: <u>计算机科学与技术</u> 班级: <u>173040105</u> 班

课程名 称	编译原理课程设计	实验课 时	4		
实验项 目	手工构造 Tiny 语言的词法分析器	实验时间	2019年4月2日、2019年4月9日		
实验目的	1. 熟悉 Tiny 语言词法的特点。				
	2. 根据 Tiny 语言词法构造 DFA,使其可以识别 Tiny 语言 Token。				
	3. 用 C 语言实现 Tiny 语言的词法分析器,设计数据类型、数据结构与其				
	他代码,并且可以正常编译、运行、调试。				
实验环境	▶ 设备: Microsoft Surface Pro 5 i5 8+256G				
	▶ 操作系统: Windows 10 64 位				
	➤ Linux 模拟环境: MSYS2 MinGW 64 (mintty)				
	(和在 Linux 下操作是完全一样的)				
	Shell: zsh				
	▶ 编程语言: C Language				
	→ 编译器: gcc.exe (Rev2, Built by MSYS2 project) 8.3.0				
	▶ Make: GNU Make 4.2.1 (为 x86_64-pc-msys 编译)				
	文本编辑器: VSCode 作为编辑器,文本文件采用 utf-8 编码				

一、Tiny 语言词法的特点

- ➤ Tiny 语言仅是一个由分号分隔开的语句序列,它既无过程也无声明。
- ▶ 所有的变量都是整型变量,通过对其赋值可声明变量。
- > 只有两个控制语句: if 语句和 repeat 语句,这两个控制语句本身 也可包含语句序列。
 - if 语句有一个可选的 else 部分且必须由关键字 end 结束。
 - repeat 语句需以 until 语句结束。
- ▶ read 语句和 write 语句完成输入/输出。
- ➤ TINY 的表达式局限于布尔表达式和整型算术表达式。
 - 布尔表达式由对两个算术表达式的比较组成,使用<与=比较算符。布尔表达式只作为测试出现在控制语句中。
 - 算术表达式可以包括整型常数、变量、参数以及4个整型算符 +、一、*、/,支持小括号改变运算优先级。
- ▶ 代码格式自由,空格、tab、换行都可以用来作为分隔符。
- ▶ 在花括号中可以有注释,但注释不能嵌套。
- ▶ 遵循最长子串原则。
- ▶ 标识符要求由字母组成,大小写敏感。
 - ▶ 数支持无符号整数。

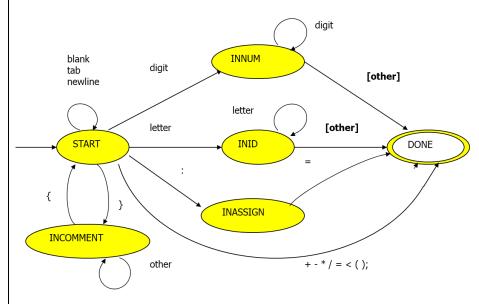
Tiny 语言的 Token 共有 22 种,如下表:

保留字	运算符	其他
if	+	
then	=	number
else	*	identifier
end	/	

实验内 容

repeat	=	
until	<	
read	(
write)	
	;	
	:=	

二、识别 Tiny 语言 Token 的 DFA 设计



三、重要的数据类型、数据结构设计

1. 首先,为了合理利用计算机资源,为数组分配合适的大小,因此需要限定文件名最大长度、token 最大长度等,这就需要定义一些常量:

```
// 定义布尔值
#define TRUE (1)
#define FALSE (0)

// 文件名最大长度 120 个字符
#define MAX_FILENAME_LENGTH 120

// 一个 token 的长度最大为 40
#define MAX_TOKEN_LENGTH 40

// Tiny 源代码一行最多 255 个字符
```

```
#define MAX_BUFFER_LENGTH 256

// Tiny 语言一共有 8 个保留字

#define MAX_RESERVED_NUMBER 8
```

2. Tiny 语言共有 22 个 Token 类型,可以用 C 语言中的枚举数据类型实现。因此,定义一个 enum TokenType,并用 typedef 将其定义为类型 TokenType,方便之后将枚举 TokenType 作为函数返回值使用:

```
typedef enum TokenType {
 // 标注特殊状态的 Type,
 // 它们不代表实际的 Token, 只是代表遇到文件尾和错误时,
getToken() 函数的返回值
 ENDFILE,
 ERROR,
 // Tiny 语言的 8 个保留关键字
 IF,
 THEN,
 ELSE,
 END,
 REPEAT,
 UNTIL,
 READ,
 WRITE,
 // 标识符
 ID,
 // 数字
 NUM,
 // 运算符
 ASSIGN,
 EQ,
```

```
LT,
PLUS,
MINUS,
TIMES,
OVER,
LPAREN,
RPAREN,
SEMI
} TokenType;
```

3. 如上图所示,在识别 Tiny 语言 Token 的 DFA 中,一共有六个状态,分别为 START、INASSIGN、INCOMMENT、INNUM、INID、DONE。同样可以将其定义为枚举并用 typedef 定义为类型方便后续调用:

```
typedef enum StateType {
   START,
   INASSIGN,
   INCOMMENT,
   INNUM,
   INID,
   DONE
} StateType;
```

4. 由于保留关键字和标识符同为字符序列,在特征上没有差异,因此需要定义保留关键字表,将保留关键字的字符序列映射到它们对应的 Token 类型上,这样一一对应的映射关系可以采用 C 语言中的结构体实现。如下所示,在结构体类型 ReservedWord 中,成员 string 存储了保留关键字的字符序列,而成员 token 则存储了保留关键字对应的 Token 类型。

```
typedef struct ReservedWord {
```

```
char* string;
TokenType token;
} ReservedWord;
```

然后,就可以声明一个长度为 8 的 ReservedWord[]数组,存放 Tiny 语言的 8 个保留关键字映射方式所对应的结构体:

四、实现的关键代码设计

1. 全局变量设计

首先,按照要求,程序需要从 tny 文本文件中读取 Tiny 语言源代码,将其进行词法分析后,将分析的结果保存到[源文件名].txt 文件中。所以,首先需要两个保存文件名的 char[]类型变量和两个控制文件 I/O 的 FILE 类型变量:

```
char source_file_name[MAX_FILENAME_LENGTH + 1];
char result_file_name[MAX_FILENAME_LENGTH + 1];
FILE* source_file;
FILE* result_file;
```

其次,在进行词法扫描时,程序是逐行读取源代码的,且每行代码不得 超过 255 个字符。这就需要创建一个缓存区每次按行缓存源代码内容。同 时, 也需要记录行号, 方便后续输出。因此, 需要声明下面五个变量:

```
// 当前行号
int line_number = 0;

// 缓存当前行的内容
char line_buffer[MAX_BUFFER_LENGTH];

// 当前行读取到的下标
int line_buffer_index = 0;

// 当前行的实际字符数
int line_buffer_size = 0;

// 确保当前行还没有结束,为了预防 ungetNextChar() 在遇到 EOF时出错
int is_EOF = FALSE;
```

2. 命令行调用与输入输出设计

在 C 语言程序中, main 函数的定位常为:

```
int main(int argc, char* argv[]);
```

其中,argc 表示参数的数目,argv 是传入的所有参数的值的集合。在 执行程序时,参数至少会有一个,即当前程序的文件名(argv[0])。考虑到 该程序只能接收一个 tny 源代码文件名作为参数,需要在 main 函数的开始 做如下判断, 当参数格式不正确时, 拒绝执行并且提示用户正确的使用格式:

```
if (argc != 2) {
  printf("Usage: %s <filename>\n", argv[0]);
  exit(1);
}
```

并且,在人们的使用习惯中,输入文件名时往往会省略掉扩展名。这也需要在程序中进行检测,如果输入的文件名中不包含扩展名,则为其补上:

```
strcpy(source_file_name, argv[1]);
if (strchr(source_file_name, '.') == NULL) {
```

```
strcat(source_file_name, ".tny");
```

然后就可以用 fopen()函数读取文件了,需要注意的是,用户指定的文件不一定存在。如果文件无法读取,同样需要显式报错并以非零状态码退出程序:

```
source_file = fopen(source_file_name, "r");
if (source_file == NULL) {
  printf("File %s not found\n", source_file_name);
  exit(1);
}
```

接下来需要为后续输出做准备,用 fprintf 输出词法扫描的结果即可。根据要求,需要结合源文件的名称,将分析的结果保存到**[源文件名].txt** 文 件 中 , 所 以 需 要 先 把 source_file_name 的 内 容 复 制 到 result_file_name 中,再将后半部分替换为「.txt」。然后用 fopen 以写模式打开文件,如果无法写入的话也要显式报错并以非零状态码退出程序:

```
strcpy(result_file_name, source_file_name);
  *strstr(result_file_name, ".tny") = '\0';
  strcat(result_file_name, ".txt");
  result_file = fopen(result_file_name, "w");
  if (result_file == NULL) {
    printf("File %s cannot be written\n",
    source_file_name);
    exit(1);
}
```

最后,按照格式要求,往文件里输入「TINY COMPILATION:」作为开头,再循环运行 getToken()函数,不断截取 Token 并输出即可。在源代码文件全部处理完后,再在 Shell 里显示提示,告知用户词法分析的结果保存在了[源文件名].txt 文件中。

```
fprintf(result_file, "TINY COMPILATION:\n");
while (getToken() != ENDFILE) {
}
printf("The lexical analysis result is saved to
file %s\n", result_file_name);
```

3. getToken()函数设计

这是整个词法扫描程序最重要的一个函数,因为实际上做完前面的准备工作后,后面的时间程序都是在不断的运行 getToken()函数。因为我们是逐行读取 tny 源文件内容的,所以首先要初始化一些变量,如下所示:

```
// 存放当前 token 的字符串

// 注意这里必须初始化为空串,否则内存中的垃圾可能会随机填充
到这里,影响后面的运行
char token_string[MAX_TOKEN_LENGTH + 1] = "";

// 标记在 token_string 中存到哪个下标了
int token_string_index = 0;

// 作为返回值的 token
TokenType current_token;
```

然后,就是一个经典的双层 case 处理关键字了。根据 Tiny 语言的 DFA 图,设计处理代码如下:

```
// 当前处于 DFA 中的哪个状态,一共有 START, INASSIGN,
INCOMMENT, INNUM,
// INID, DONE 六种
StateType state = START;
// 跑 DFA, 只要没到终态就一直跑
while (state != DONE) {
```

```
// 取出一个字符做判断
int c = getNextChar();
// 标明当前的字符是否可以被保存进 token string 中,
// 一开始先假定这个字符是可以被保存进入 token_string 的
int can_be_saved = TRUE;
// 双层 case 法
switch (state) {
 case START:
   if (isdigit(c)) {
     state = INNUM;
   } else if (isalpha(c)) {
     state = INID;
   } else if (c == ':') {
     state = INASSIGN;
   } else if (c == ' ' || c == '\t' || c == '\n') {
     can_be_saved = FALSE;
   } else if (c == '{') {
     can_be_saved = FALSE;
     state = INCOMMENT;
   } else {
     state = DONE;
     switch (c) {
       case EOF:
        can_be_saved = FALSE;
        current_token = ENDFILE;
        break;
       case '=':
        current_token = EQ;
        break;
       case '<':
```

```
current_token = LT;
       break;
     case '+':
       current_token = PLUS;
       break;
     case '-':
       current_token = MINUS;
       break;
     case '*':
       current_token = TIMES;
       break;
     case '/':
       current_token = OVER;
       break;
     case '(':
       current_token = LPAREN;
       break;
     case ')':
       current_token = RPAREN;
       break;
     case ';':
       current_token = SEMI;
       break;
     default:
       current_token = ERROR;
       break;
   }
 }
 break;
case INCOMMENT:
```

```
can_be_saved = FALSE;
 if (c == EOF) {
   state = DONE;
   current_token = ENDFILE;
 } else if (c == '}') {
   state = START;
 }
 break;
case INASSIGN:
 state = DONE;
 if (c == '=') {
   current_token = ASSIGN;
 } else {
   ungetNextChar();
   can_be_saved = FALSE;
   current_token = ERROR;
 }
 break;
case INNUM:
 if (!isdigit(c)) {
   ungetNextChar();
   can_be_saved = FALSE;
   state = DONE;
   current_token = NUM;
 }
 break;
case INID:
 if (!isalpha(c)) {
   ungetNextChar();
   can_be_saved = FALSE;
```

```
state = DONE;
        current_token = ID;
      }
      break;
    case DONE:
    default:
      // 如果已经进行到了 DONE 状态, 那应该已经跳出了, 不可
能进入到 switch 中
      // 所有的状态在上面都涉及到了,不可能出现 default 响应
的情况
      // 如果出现了上述两种情况,那一定是出现了不可思议的问
题,直接跳出就好了
      fprintf(result_file, "Scanner Bug: state= %d\n",
state);
      state = DONE;
      current token = ERROR;
      break;
   }
   if (can be saved && token string index <=</pre>
MAX_TOKEN_LENGTH) {
    // 如果当前处理的字符是多字符 token 的一部分,而且 token
没有过长的话,就保存下来
    token_string[token_string_index++] = (char)c;
   }
   if (state == DONE) {
    token_string[token_string_index] == '\0';
    if (current_token == ID) {
```

```
current_token =
distinguishReservedWordAndIdentifer(token_string);
}
}
}
```

在双层 case 处理的过程中,我创建了一个 can_be_saved 变量作为flag,还调用了编写的 getNextChar()函数、ungetNextChar()函数和distinguishReservedWordAndIdentifer()函数,接下来对这一个变量与三个函数逐一说明。

can_be_saved 变量,顾名思义,是判断当前的字符需不需要被保存到token_string内。因为有一些元素,比如标识符,关键字还有数字,是可能由多个字符构成的。如果遇到这种情况,就需要在下一次循环中继续往token_string填充字符,直到结束这个状态(数字或标识符)。

getNextChar()函数,顾名思义,是取出下一个字符判断的。思路是每次取一行源码,然后挨个读取字符,如果这一行读取完了,再读下一行,并且输出这一行的源码和行号。在这里我发现了原版 tiny 编译器的一个 bug,就是如果 tny 文件的末尾不是空行,那么输出的行号格式就会错乱,如下图:

```
until'x'='0;CRLE

write'fact'{'output'factorial'of'x'}CRLE

and

不以空行结尾
```

我觉得这是这个程序鲁棒性不强的地方,怎么能保证源码文件一定以空行结尾呢?因此,我引入了currentLineHasLF()方法,它只有一行代码:

```
int currentLineHasLF(void) { return
line_buffer[line_buffer_size - 1] == '\n'; }
```

但是却可以检测到行尾是不是以回车结束的。如果行尾不是以回车结束,这样的情况只有一种,就是它不仅是行尾,也是文件尾。这时候就需要做特殊处理。我写的 getNextChar()代码如下,处理的地方已经用注释作了说明:

```
int getNextChar(void) {
    if (line_buffer_index < line_buffer_size) {
        // 如果当前读取的内容在缓存区边界内,就直接返回下标对应的
        字符,并将下标加一
        return line_buffer[line_buffer_index++];
    } else {
        // 如果当前读取的内容不在当前行缓存区边界内,说明这一行已
        经读取完了

        // C 库函数 char *fgets(char *str, int n, FILE
        *stream) 从指定的流 stream 读取一行,并把它存储在 str 所指向
```

```
的字符串内。当读取 (n-1) 个字符时,或者读取到换行符时,或者到
达文件末尾时,它会停止,具体视情况而定。
   // 这里读取的是 (MAX_BUFFER_LENGTH - 1) 个字符,是为了给
\0 腾出一个字节
   if (fgets(line buffer, MAX BUFFER LENGTH - 1,
source file)) {
    // 如果 source file 中的内容还有,打印这一行的内容,附
带行号
    // 行号加一
    line number++;
    // 记录这一行的实际字符数
    line buffer size = strlen(line buffer);
    // 如果 EOF 没有独立成行的话,最后一行字符是没有 \n 的,
需要补一个 \n 让其输出换行
    if (!currentLineHasLF()) {
      line buffer[line buffer size++] = '\n';
      line buffer[line buffer size] = '\0';
      fprintf(result file, "%4d: %s", line number,
line buffer);
      line buffer[--line buffer size] = '\0';
    } else {
      fprintf(result_file, "%4d: %s", line_number,
line_buffer);
    }
    // 将当前行读取到的下标重置为 0
    line_buffer_index = 0;
    // 返回当前行的第一个字符,并将下标加一
    return line buffer[line buffer index++];
   } else {
```

```
// 如果 source_file 中的内容已经全部读取完了,就返回
EOF

is_EOF = TRUE;
if (currentLineHasLF()) {
    line_number++;
    }
    return EOF;
}
```

而我的 getNextChar()函数即使遇到文件尾没有空行的情况,也能正常处理,鲁棒性更强,如下图所示:

```
6 if 0 > x then { don't compute if
                                       fact := 1; CRUE
                               8
                                       repeat CRLE
10: ;
11: until x = 0;
                                          fact := fact % x; CRUE
                               10
                                          \rightarrowx := x - 1; CRLE
                                       until x = 0; CRLE
                               11
                                       write fact { output factoria
                               12
                                         文件尾不是空行
     12: reserved word: write
                                         EOF在第13行,此处文件结束
                                         程序也正确在13行输出了EOF
     13: reserved word, end
     13: EOF
                             Nor length: 253 lines: 13
                                                        Ln:13 Col:4
```

ungetNextChar()函数,顾名思义,是处理状态转换图中「回退一个字符」那一步的操作,将刚刚读取到的下一个字符,退回缓存区中。当然,如果「下一个字符」就是文件尾的话,那也就没有回退的必要了。代码如下:

```
void ungetNextChar(void) {
   // 如果下一个字符就是文件尾,那就没有回退的必要了。
   if (!is_EOF) {
      line_buffer_index--;
```

```
}
```

distinguishReservedWordAndIdentifer()函数,顾名思义,作用是判断一个标识符是不是关键字。方法是查询关键字表,看当前识别出的这个标识符是否对应。因为关键字很少,只有8个,所以只需要线性查找一遍关键字表即可。代码如下:

```
TokenType distinguishReservedWordAndIdentifer(char*
string) {
  for (int i = 0; i < MAX_RESERVED_NUMBER; i++) {
    if (!strcmp(string, reserved_words[i].string)) {
      return reserved_words[i].token;
    }
  }
  return ID;
}</pre>
```

关键字表的定义在前文已经给出,不再赘述。

在双层 case 循环结束之后,整个源码文件就已经全部被遍历完了。而这时,原版的编译器又出现了一个问题,明明 EOF 是在下一行了,行号也输出的是下一行的行号。但是,缩进居然和上一行的关键字是同一个缩进,这就很尴尬了,成了四不像,如下图所示:

```
10: ID, name= x
10: -
10: NUM, val= 1
10: ;
11: until x = 0;
11: reserved word: until
11: ID, name= x
11: =
11: NUM, val= 0
11: ;
12: write fact { output factorial of x }
12: reserved word: write
12: ID, name= fact
13: end
13: reserved word: end
14: EOF
14行的编进不正确,应该和前面的13行源码的输出对齐

D:\OneDrive\SCU\Study\Projects in Principles of Compiler\Week 6\TINY 编译器源码
```

因此我在这里又做了一个检测。如果文件尾无空行时,那么 EOF 作为上一行的一份子输出(前文有截图);如果文件尾有空行时,那么 EOF 独立成行输出,缩进和其他行的源代码输出对齐,代码如下:

```
// 当 EOF 独立成行时,这里需要用行号的方式输出
if (current_token == ENDFILE && currentLineHasLF()) {
   fprintf(result_file, "%4d: ", line_number);
} else {
   fprintf(result_file, "\t%d: ", line_number);
}
```

做了这个调整后,输出就正确了:

最后,需要按照规定的格式将 token 打印出来。为此编写了一个方法,printfToken(),只是简单地用 switch 判断了一下 token 类型,然后输出就好了:

```
void printToken(TokenType token, char* string) {
 switch (token) {
   case IF:
   case THEN:
   case ELSE:
   case END:
   case REPEAT:
   case UNTIL:
   case READ:
   case WRITE:
     fprintf(result_file, "reserved word: %s\n",
string);
     break;
   case ASSIGN:
     fprintf(result_file, ":=\n");
     break;
   case LT:
     fprintf(result_file, "<\n");</pre>
     break;
   case EQ:
     fprintf(result_file, "=\n");
     break;
   case LPAREN:
     fprintf(result_file, "(\n");
     break;
   case RPAREN:
```

```
fprintf(result_file, ")\n");
 break;
case SEMI:
 fprintf(result_file, ";\n");
 break;
case PLUS:
 fprintf(result_file, "+\n");
 break;
case MINUS:
 fprintf(result_file, "-\n");
 break;
case TIMES:
 fprintf(result_file, "*\n");
 break;
case OVER:
 fprintf(result_file, "/\n");
 break;
case ENDFILE:
 fprintf(result_file, "EOF\n");
 break;
case NUM:
 fprintf(result_file, "NUM, val= %s\n", string);
 break;
case ID:
 fprintf(result_file, "ID, name= %s\n", string);
 break;
case ERROR:
 fprintf(result_file, "ERROR: %s\n", string);
 break;
default:
```

```
// 永不发生
     fprintf(result_file, "Unknown token: %d\n", token);
  }
   至此,我的关键代码全部都编写完了。
五、附录-源代码
types.h
#ifndef __TYPES_H__
#define __TYPES_H__
// 定义布尔值
#define TRUE (1)
#define FALSE (0)
// 文件名最大长度 120 个字符
#define MAX_FILENAME_LENGTH 120
// 一个 token 的长度最大为 40
#define MAX_TOKEN_LENGTH 40
// Tiny源代码一行最多 255 个字符
#define MAX_BUFFER_LENGTH 256
// Tiny 语言一共有 8 个保留字
#define MAX RESERVED NUMBER 8
// 定义 Token 的类型
typedef enum TokenType {
  // 标注特殊状态的 Type,
```

```
// 它们不代表实际的 Token, 只是代表遇到文件尾和错误时,
getToken() 函数的返回值
 ENDFILE,
 ERROR,
 // Tiny 语言的 8 个保留关键字
 IF,
 THEN,
 ELSE,
 END,
 REPEAT,
 UNTIL,
 READ,
 WRITE,
 // 标识符
 ID,
 // 数字
 NUM,
 // 运算符
 ASSIGN,
 EQ,
 LT,
 PLUS,
 MINUS,
 TIMES,
 OVER,
 LPAREN,
 RPAREN,
 SEMI
} TokenType;
```

```
// 定义词法扫描 DFA 的状态
typedef enum StateType {
  START,
  INASSIGN,
  INCOMMENT,
 INNUM,
 INID,
 DONE
} StateType;
typedef struct ReservedWord {
 char* string;
 TokenType token;
} ReservedWord;
// 8 个保留字对应的 Token 类型
ReservedWord reserved_words[MAX_RESERVED_NUMBER] = {
                 {"then", THEN}, {"else", ELSE},
   {"if", IF},
{"end", END},
   {"repeat", REPEAT}, {"until", UNTIL}, {"read", READ},
{"write", WRITE}};
#endif
```

main.h

```
#ifndef __MAIN_H_
#define __MAIN_H_

#include <ctype.h>
#include <stdio.h>
```

```
#include <stdlib.h>
#include <string.h>
#include "types.h"
// 主程序的变量
extern char source_file_name[MAX_FILENAME_LENGTH + 1];
extern char result_file_name[MAX_FILENAME_LENGTH + 1];
extern FILE* source file;
extern FILE* result file;
// 词法扫描的变量
// 当前行号
extern int line number;
// 缓存当前行的内容
extern char line buffer[MAX BUFFER LENGTH];
// 当前行读取到的下标
extern int line buffer index;
// 当前行的实际字符数
extern int line buffer size;
// 确保当前行还没有结束,为了预防 ungetNextChar() 在遇到 EOF
时出错
extern int is_EOF;
int main(int argc, char* argv[]);
// 不断的读取 source 中的字符,凑成一个 Token 就返回
TokenType getToken(void);
// 取出下一个字符
int getNextChar(void);
```

```
// 将下一个字符退回缓存区
void ungetNextChar(void);
// 区分「保留字」和「普通的标识符」
TokenType distinguishReservedWordAndIdentifer(char*
string);
// 按照特定格式打印当前 Token
void printToken(TokenType, char* string);
// 检测当前行是否以\n 结尾
int currentLineHasLF(void);
#endif
main.c
#include "main.h"
// 主程序的变量
char source_file_name[MAX_FILENAME_LENGTH + 1];
char result_file_name[MAX_FILENAME_LENGTH + 1];
FILE* source_file;
FILE* result_file;
// 词法扫描的变量
// 当前行号
int line number = 0;
// 缓存当前行的内容
char line_buffer[MAX_BUFFER_LENGTH];
// 当前行读取到的下标
```

int line_buffer_index = 0;

```
// 当前行的实际字符数
int line_buffer_size = 0;
// 确保当前行还没有结束,为了预防 ungetNextChar() 在遇到 EOF
时出错
int is_EOF = FALSE;
int main(int argc, char* argv[]) {
 if (argc != 2) {
   printf("Usage: %s <filename>\n", argv[0]);
   exit(1);
 }
 strcpy(source_file_name, argv[1]);
 if (strchr(source_file_name, '.') == NULL) {
   strcat(source_file_name, ".tny");
 }
 source_file = fopen(source_file_name, "r");
 if (source_file == NULL) {
   printf("File %s not found\n", source file name);
   exit(1);
 }
 strcpy(result_file_name, source_file_name);
 *strstr(result_file_name, ".tny") = '\0';
 strcat(result_file_name, ".txt");
 result_file = fopen(result_file_name, "w");
 if (result_file == NULL) {
   printf("File %s cannot be written\n",
source_file_name);
```

```
exit(1);
 }
 fprintf(result_file, "TINY COMPILATION:\n");
 while (getToken() != ENDFILE) {
 }
 printf("The lexical analysis result is saved to
file %s\n", result file name);
 return 0;
}
TokenType getToken(void) {
 // 存放当前 token 的字符串
 // 注意这里必须初始化为空串,否则内存中的垃圾可能会随机填充
到这里,影响后面的运行
 char token_string[MAX_TOKEN_LENGTH + 1] = "";
 // 标记在 token_string 中存到哪个下标了
 int token string index = 0;
 // 作为返回值的 token
 TokenType current_token;
 // 当前处于 DFA 中的哪个状态,一共有 START, INASSIGN,
INCOMMENT, INNUM,
 // INID, DONE 六种
 StateType state = START;
 // 跑 DFA, 只要没到终态就一直跑
 while (state != DONE) {
```

```
// 取出一个字符做判断
int c = getNextChar();
// 标明当前的字符是否可以被保存进 token string 中,
// 一开始先假定这个字符是可以被保存进入 token_string 的
int can_be_saved = TRUE;
// 双层 case 法
switch (state) {
 case START:
   if (isdigit(c)) {
     state = INNUM;
   } else if (isalpha(c)) {
     state = INID;
   } else if (c == ':') {
     state = INASSIGN;
   } else if (c == ' ' || c == '\t' || c == '\n') {
     can_be_saved = FALSE;
   } else if (c == '{') {
     can_be_saved = FALSE;
     state = INCOMMENT;
   } else {
     state = DONE;
     switch (c) {
       case EOF:
        can_be_saved = FALSE;
        current_token = ENDFILE;
        break;
       case '=':
        current_token = EQ;
        break;
       case '<':
```

```
current_token = LT;
       break;
     case '+':
       current_token = PLUS;
       break;
     case '-':
       current_token = MINUS;
       break;
     case '*':
       current_token = TIMES;
       break;
     case '/':
       current_token = OVER;
       break;
     case '(':
       current_token = LPAREN;
       break;
     case ')':
       current_token = RPAREN;
       break;
     case ';':
       current_token = SEMI;
       break;
     default:
       current_token = ERROR;
       break;
   }
 }
 break;
case INCOMMENT:
```

```
can_be_saved = FALSE;
 if (c == EOF) {
   state = DONE;
   current_token = ENDFILE;
 } else if (c == '}') {
   state = START;
 }
 break;
case INASSIGN:
 state = DONE;
 if (c == '=') {
   current_token = ASSIGN;
 } else {
   ungetNextChar();
   can_be_saved = FALSE;
   current_token = ERROR;
 }
 break;
case INNUM:
 if (!isdigit(c)) {
   ungetNextChar();
   can_be_saved = FALSE;
   state = DONE;
   current_token = NUM;
 }
 break;
case INID:
 if (!isalpha(c)) {
   ungetNextChar();
   can_be_saved = FALSE;
```

```
state = DONE;
        current_token = ID;
      }
      break;
    case DONE:
    default:
      // 如果已经进行到了 DONE 状态, 那应该已经跳出了, 不可
能进入到 switch 中
      // 所有的状态在上面都涉及到了,不可能出现 default 响应
的情况
      // 如果出现了上述两种情况,那一定是出现了不可思议的问
题,直接跳出就好了
      fprintf(result_file, "Scanner Bug: state= %d\n",
state);
      state = DONE;
      current token = ERROR;
      break;
   }
   if (can be saved && token string index <=</pre>
MAX_TOKEN_LENGTH) {
    // 如果当前处理的字符是多字符 token 的一部分,而且 token
没有过长的话,就保存下来
    token_string[token_string_index++] = (char)c;
   }
   if (state == DONE) {
    token_string[token_string_index] == '\0';
    if (current_token == ID) {
```

```
current_token =
distinguishReservedWordAndIdentifer(token_string);
    }
   }
 }
 // 当 EOF 独立成行时,这里需要用行号的方式输出
 if (current_token == ENDFILE && currentLineHasLF()) {
   fprintf(result file, "%4d: ", line number);
 } else {
   fprintf(result_file, "\t%d: ", line_number);
 }
 printToken(current_token, token_string);
 return current_token;
}
int getNextChar(void) {
 if (line buffer index < line buffer size) {</pre>
   // 如果当前读取的内容在缓存区边界内,就直接返回下标对应的
字符,并将下标加一
  return line_buffer[line_buffer_index++];
 } else {
   // 如果当前读取的内容不在当前行缓存区边界内,说明这一行已
经读取完了
   // C 库函数 char *fgets(char *str, int n, FILE
*stream) 从指定的流 stream
```

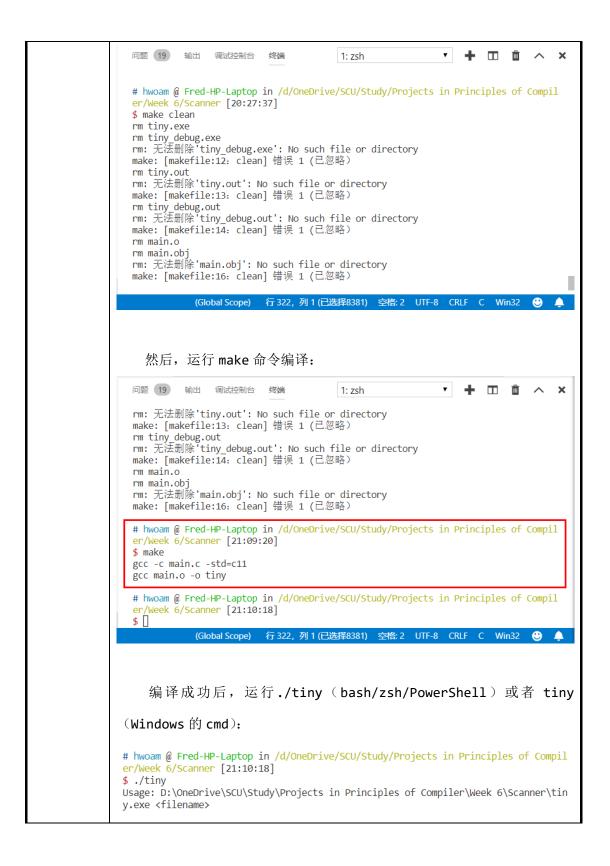
```
// 读取一行, 并把它存储在 str 所指向的字符串内。当读取 (n-
1)
  // 个字符时,或者读取到换行符时,或者到达文件末尾时,它会
停止,具体视情况而定。
  // 这里读取的是 (MAX BUFFER LENGTH - 1) 个字符,是为了给
\0 腾出一个字节
  if (fgets(line_buffer, MAX_BUFFER_LENGTH - 1,
source_file)) {
    // 如果 source file 中的内容还有,
    // 打印这一行的内容, 附带行号
    // 行号加一
    line number++;
    // 记录这一行的实际字符数
    line_buffer_size = strlen(line_buffer);
    // 如果 EOF 没有独立成行的话,最后一行字符是没有 \n 的,
需要补一个 \n
    // 让其输出换行
    if (!currentLineHasLF()) {
      line_buffer[line_buffer_size++] = '\n';
      line buffer[line buffer size] = '\0';
      fprintf(result file, "%4d: %s", line number,
line_buffer);
      line_buffer[--line_buffer_size] = '\0';
    } else {
      fprintf(result_file, "%4d: %s", line_number,
line buffer);
    }
    // 将当前行读取到的下标重置为 0
    line_buffer_index = 0;
    // 返回当前行的第一个字符,并将下标加一
```

```
return line_buffer[line_buffer_index++];
   } else {
     // 如果 source_file 中的内容已经全部读取完了,就返回
EOF
     is_EOF = TRUE;
     if (currentLineHasLF()) {
       line_number++;
     }
     return EOF;
   }
 }
}
void ungetNextChar(void) {
 // 如果下一个字符就是文件尾,那就没有回退的必要了。
 if (!is_EOF) {
   line_buffer_index--;
 }
}
TokenType distinguishReservedWordAndIdentifer(char*
string) {
 for (int i = 0; i < MAX_RESERVED_NUMBER; i++) {</pre>
   if (!strcmp(string, reserved_words[i].string)) {
     return reserved_words[i].token;
   }
 }
 return ID;
```

```
void printToken(TokenType token, char* string) {
 switch (token) {
   case IF:
   case THEN:
   case ELSE:
   case END:
   case REPEAT:
   case UNTIL:
   case READ:
   case WRITE:
     fprintf(result_file, "reserved word: %s\n",
string);
     break;
   case ASSIGN:
     fprintf(result_file, ":=\n");
     break;
   case LT:
     fprintf(result_file, "<\n");</pre>
     break;
   case EQ:
     fprintf(result_file, "=\n");
     break;
   case LPAREN:
     fprintf(result_file, "(\n");
     break;
   case RPAREN:
     fprintf(result_file, ")\n");
     break;
   case SEMI:
     fprintf(result_file, ";\n");
```

```
break;
 case PLUS:
   fprintf(result_file, "+\n");
   break;
 case MINUS:
   fprintf(result_file, "-\n");
   break;
 case TIMES:
   fprintf(result_file, "*\n");
   break;
 case OVER:
   fprintf(result_file, "/\n");
   break;
 case ENDFILE:
   fprintf(result_file, "EOF\n");
   break;
 case NUM:
   fprintf(result_file, "NUM, val= %s\n", string);
   break;
 case ID:
   fprintf(result_file, "ID, name= %s\n", string);
   break;
 case ERROR:
   fprintf(result_file, "ERROR: %s\n", string);
   break;
 default:
   // 永不发生
   fprintf(result_file, "Unknown token: %d\n", token);
}
```

```
int currentLineHasLF(void) { return
          line_buffer[line_buffer_size - 1] == '\n'; }
         makefile
          objects = main.o
          tiny: $(objects)
            gcc $(objects) -o tiny
          main.o: main.c main.h types.h
            gcc -c main.c -std=c11
          .PHONY: clean
          clean:
            -rm tiny.exe
            -rm tiny_debug.exe
            -rm tiny.out
            -rm tiny_debug.out
            -rm main.o
            -rm main.obj
          all: tiny
            首先,运行 make clean 做一点清理工作,把旧的中间文件删除(已经
实验结
         考虑到了.exe和.out,以及.obj和.o文件可能在不同系统下生成的差异):
  果
```

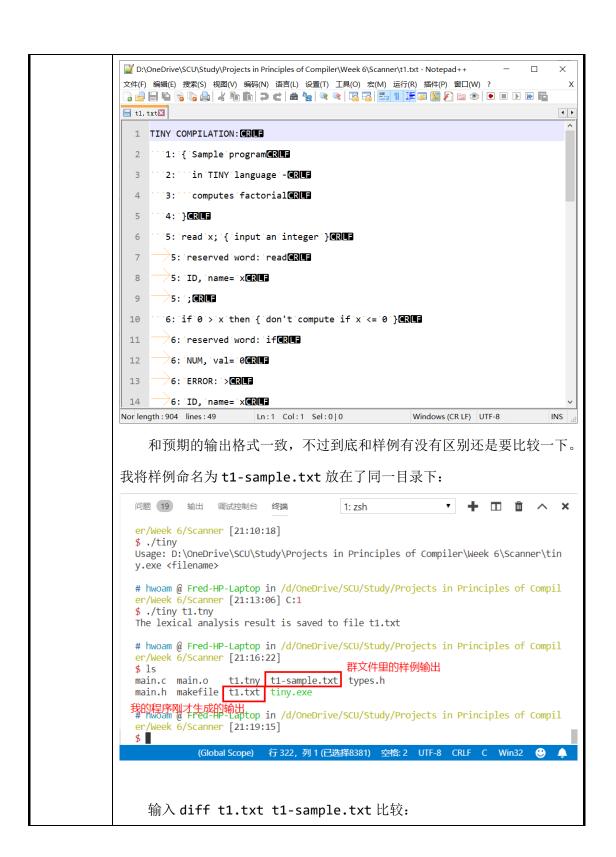


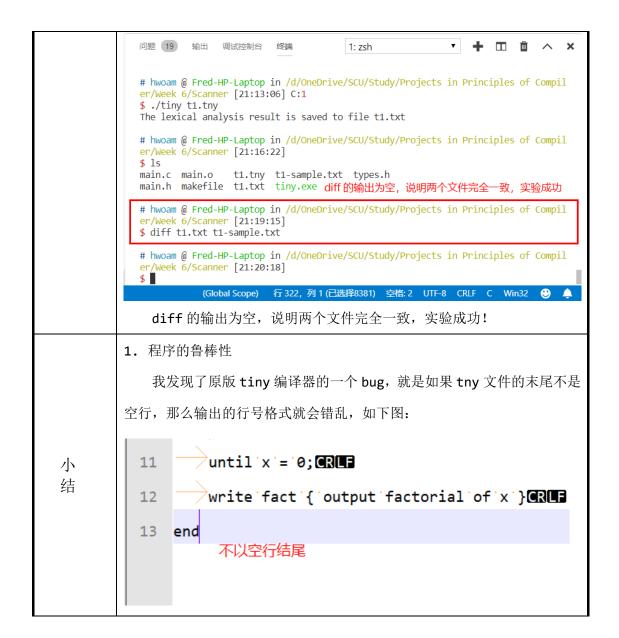


如图,如果终端是 bash/zsh/PowerShell,那么是上面第一张图显示的提示。如果是 cmd,那么是上面第二张图的提示。即提示了用户「正确使用方法」是「tiny 文件 <filename>」的格式调用:

然后输入./tiny t1.tny 调用程序,如果终端不是bash/zsh/PowerShell而是cmd,调用命令同上,不再赘述:







我觉得这是这个程序鲁棒性不强的地方,怎么能保证源码文件一定以空行结尾呢?因此,我引入了currentLineHasLF()方法,它只有一行代码:

```
int currentLineHasLF(void) { return
line_buffer[line_buffer_size - 1] == '\n'; }
```

但是却可以检测到行尾是不是以回车结束的。如果行尾不是以回车结束,这样的情况只有一种,就是它不仅是行尾,也是文件尾。这时候就需要做特殊处理。我写的 getNextChar()代码如下,处理的地方已经用注释作了说明:

```
int getNextChar(void) {
   if (line_buffer_index < line_buffer_size) {
      // 如果当前读取的内容在缓存区边界内,就直接返回下标对应的
      字符,并将下标加一
      return line_buffer[line_buffer_index++];
   } else {
      // 如果当前读取的内容不在当前行缓存区边界内,说明这一行已
      经读取完了

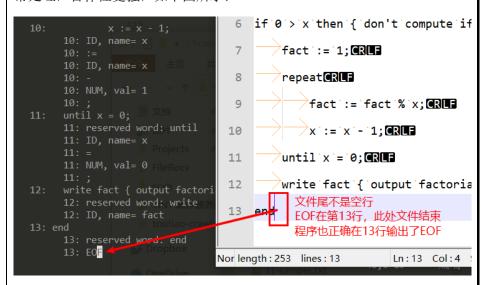
      // C 库函数 char *fgets(char *str, int n, FILE
      *stream) 从指定的流 stream 读取一行,并把它存储在 str 所指向</pre>
```

```
的字符串内。当读取 (n-1) 个字符时,或者读取到换行符时,或者到
达文件末尾时,它会停止,具体视情况而定。
   // 这里读取的是 (MAX_BUFFER_LENGTH - 1) 个字符,是为了给
\0 腾出一个字节
   if (fgets(line buffer, MAX BUFFER LENGTH - 1,
source file)) {
    // 如果 source file 中的内容还有,打印这一行的内容,附
带行号
    // 行号加一
    line number++;
    // 记录这一行的实际字符数
    line buffer size = strlen(line buffer);
    // 如果 EOF 没有独立成行的话,最后一行字符是没有 \n 的,
需要补一个 \n 让其输出换行
    if (!currentLineHasLF()) {
      line buffer[line buffer size++] = '\n';
      line buffer[line buffer size] = '\0';
      fprintf(result file, "%4d: %s", line number,
line buffer);
      line buffer[--line buffer size] = '\0';
    } else {
      fprintf(result_file, "%4d: %s", line_number,
line_buffer);
    }
    // 将当前行读取到的下标重置为 0
    line_buffer_index = 0;
    // 返回当前行的第一个字符,并将下标加一
    return line buffer[line buffer index++];
   } else {
```

```
// 如果 source_file 中的内容已经全部读取完了,就返回
EOF

is_EOF = TRUE;
if (currentLineHasLF()) {
    line_number++;
    }
    return EOF;
}
```

而我的 getNextChar()函数即使遇到文件尾没有空行的情况,也能正常处理,鲁棒性更强,如下图所示:



2. 注意缩进的区别

原版的编译器又出现了一个问题,明明 EOF 是在下一行了,行号也输出的是下一行的行号。但是,缩进居然和上一行的关键字是同一个缩进,这就很尴尬了,成了四不像,如下图所示:

```
10: ID, name= x
10: -
10: NUM, val= 1
10: ;
11: until x = 0;
11: reserved word: until
11: ID, name= x
11: =
11: NUM, val= 0
11: ;
12: write fact { output factorial of x }
12: reserved word: write
12: ID, name= fact
13: end
13: reserved word: end
14: EOF
14行的编进不正确,应该和前面的13行源码的输出对齐

D:\OneDrive\SCU\Study\Projects in Principles of Compiler\Week 6\TINY 编译器源码
```

因此我在这里又做了一个检测。如果文件尾无空行时,那么 EOF 作为上一行的一份子输出(前文有截图);如果文件尾有空行时,那么 EOF 独立成行输出,缩进和其他行的源代码输出对齐,代码如下:

```
// 当 EOF 独立成行时,这里需要用行号的方式输出
if (current_token == ENDFILE && currentLineHasLF()) {
   fprintf(result_file, "%4d: ", line_number);
} else {
   fprintf(result_file, "\t%d: ", line_number);
}
```

做了这个调整后,输出就正确了:

	3.	重温了 makefile 文件的编	写,复习了 C 语言,回顾了	diff、cat 等命
		令的使用和 vim、gcc 等程	序的使用,巩固了已有的知	口识。
	4.	熟悉了 Tiny 语言词法的特	点,并根据 Tiny 语言词法	构造 DFA,使其可
		以识别 Tiny 语言 Token,	又用 C 语言实现 Tiny 语言	言的词法分析器,
		设计数据类型、数据结构与	其他代码, 并且可以正常编	异译、运行、调试 。
		这是我过去没有尝试过的事	情,感觉学习到了很多新知	知识,加深了我对
	编译原理这门课程的理解,在成为一名优秀的985大学计算机专业			
		生的道路上迈出了坚实的一	步。	
指导老 师评 议		成绩评定:	指导教师	币签名: